Григоренко Виктор Михайлович - тел. (967) 1-7777-25

Изучаем сжатие данных и применение на конкретных примерах Плюс будет обработка текста кажется

Возможны репрессии лмао

Модули

- Фундаментальные основы кодирования и теория информации (л 1-2)
- Статистические методы (л. 3)
- Семантические методы (л. 4)
- Алгоритмическая теория информации (л. 5)
- Онтология предметной области (л. 6)
- Прикладные задачи (л. 7)

Хихи прикольные книжки

• Павлов "Теория информации для бакалавров"

Основы Базы Фундаменты

Исходное сообщение - исходные данные **Алфавит источника** - алфавит кодировки исходного сообщения **Алфавит кодирования** - алфавит итогового сообщения

| Кодовые слова | Исходное сообщение | Кодовое слово | Исходное сообщение | Кодовое слово |
|---|-----------------------|------------------|-----------------------|------------------|
| block-block | а | 000 | aa | 0 |
| block-var | b | 001 | bbb | 1 |
| var-block | С | 010 | сссс | 10 |
| var-var | d | 011 | ddddd | 11 |
| | е | 100 | eeeeee | 100 |
| | f | 101 | fffffff | 101 |
| | g | 110 | ggggggg | 110 |
| | space | 111 | space | 111 |
| | block-block | | var-var | |
| Ансамбль - последовательность иходных сообщений | | | | |
| Различимые коды - неоднозачно декодируемые (11 = bbbbbb, dddddd) | | | | |
| Префиксные коды - однозначно декодируемые | | | | |

Классификация методов сжатия

Статические - преобразование до передачи. Пример - код Хаффмана **Динамические** - преобразование во время передачи (адаптивные коды, однопроходные коды)

Как измерить сжатие? Как сравнивать?

Сложность алгоритма и степень сжатия

- При передаче скорость сжатия, скорость передачи;
- При хранении степень сжатия;

Статическая схема: 3 алгоритма для анализа

Динамическая: 2 алгоритма

Метрики

- Избыточность (redundancy) Shannon and Weaver 1949 et al
- Эффективность кода = средняя длина сообщение (average message length) Huffman 1952 et al
- Степень сжатия (compression ratio) Rubin 1976, Ruth and Kreutzer 1972 et al
- Вероятность (fixed probability assignment) p(a)
- Количество информации в исходном сообщении (энтропия)

Важно использовать оптимальный код - с минимальной избыточностью

Где используется сжатие данных

Используется при:

- Хранении
- Передаче
- Поиске
- Обработке

При сжатии испольуется хэширование - получение числа из строки по формуле В различных архитектурах широко используют код Хаффмана (степень сжатия ~50% и выше)