# Семантические методы сжатия

Как наверняка очевидно из названия - методы, учитывающие смысл сообщений. Сжатие смысла даёт одни из лучших показателей сжатия (как пример - всю Войну и Мир можно ужать в одно предложение, однако важно понимать, какой смысл нужно оставлять а какой ужимать)

#### Области применения:

- Обработка/представление изображений/видео
- Обработка/передача бизнес-информации
- Обработка текста
  - // 1 печатный лист = 28 страниц. Прикольно
- Поисковые машины
- · Big Data

# Алгоритмы:

- RLE (Run Length Encoding), CCITT
- Кодирование карты различий (Diff. Mapping)
- Словарная замена EDIFx, IBM IMS
- Свободный разбор (free-parse) ZL78, ZLW, др.
- Онтологии семантический разбор понятийной области
- Другие по хорошему можно придумать другие новые методы

#### - / IV

RLE

Пары (с, І), где с - яркость/цвет, І - длина последовательности пикселей одной яркости/цвета

### Diff. Mapping

... - то же самое, что и RLE, но вместо с -  $\Delta c$  - разница яркости/цвета

#### Сжатие деловой информации

RLE - с - дорожка нулей/пробелов/одинаковых записей, I - длина

### Словарная замена

Протоколы EDIFx, IBM IMS (42.1% сжатия) Пример - 01890\_ABCD\_LMN 0, B, C, D, M, N - Letter code; 1890 - Number code A, L - blank code

## Алгоритмы сжатия текстовых файлов

- Словарные методы Hahn, 1974
- Словари окончаний слов, Tropper, 1982
- Программный выбор суффиксов/приставок
- Программный выбор пар словосочетаний
- Морфологические словари
- Лексические словари
  Характеристик слова около 50. Neat

#### Связи между статистическими и семантическими алгоритмами

Чем однороднее строка - тем лушче сжатие (статистика? Статистика) Алгоритмы по типу diff. mapping, Hahn, Tropper работают в специализированных обстановках в то время, когда коды Хаффмана, Зива-Лемпеля работают всегда

# Алгоритмы с применением кодовых книг (codebooks)

Суть - составить словарь предметной области, где коду в соответствие ставится некий смысл

Следующая лекция - кусок из теории информации, через лекцию - лаба